

## Seminarul 7

1. i) Estimați parametrul necunoscut  $p \in (0, 1)$  pentru distribuția binomială a unei caracteristici cercetate:  $X \sim \text{Bino}(N, p)$ , unde  $N \in \mathbb{N}^*$  este cunoscut, cu metoda momentelor, respectiv metoda verosimilității maxime. Sunt estimatorii obținuți nedeplasați, respectiv consistenți?

ii) Într-o urnă sunt bile albe și negre. Proporția de bile albe  $p \in (0, 1)$  este necunoscută. În urma a  $n = 6$  serii a câte  $N = 5$  extrageri cu returnarea bilei extrase în urnă s-au obținut: 3, 4, 2, 0, 2, respectiv 1, bile albe. Estimați valoarea lui  $p$  cu metoda momentelor, respectiv metoda verosimilității maxime.

R: i) Fie  $X_1, \dots, X_n$  variabile de selecție și  $x_1, \dots, x_n$  date statistice pentru  $X$ .

Metoda momentelor:  $E(X) = Np = \frac{1}{n} \sum_{i=1}^n X_i \implies \hat{p}(X_1, \dots, X_n) = \frac{1}{nN} \sum_{i=1}^n X_i$  estimator pentru parametrul necunoscut  $p$ .

Metoda verosimilității maxime:  $P(X = x) = C_N^x p^x (1-p)^{N-x}, x \in \{0, 1, \dots, N\} \implies L(x_1, \dots, x_n; p) = \prod_{i=1}^n P(X = x_i) = \prod_{i=1}^n C_N^{x_i} p^{x_i} (1-p)^{N-x_i} = \prod_{i=1}^n C_N^{x_i} \cdot p^{\sum_{i=1}^n x_i} (1-p)^{nN - \sum_{i=1}^n x_i} \implies \ln L(x_1, \dots, x_n; p) = \sum_{i=1}^n \ln C_N^{x_i} + \sum_{i=1}^n x_i \ln p + (nN - \sum_{i=1}^n x_i) \ln(1-p) \implies \frac{\partial \ln L}{\partial p}(x_1, \dots, x_n; p) = \frac{1}{p} \sum_{i=1}^n x_i - \frac{1}{1-p} (nN - \sum_{i=1}^n x_i)$ . Deci,  $\frac{\partial \ln L}{\partial p}(x_1, \dots, x_n; p) = 0 \implies p = \frac{1}{nN} \sum_{i=1}^n x_i$ ;  $\frac{\partial^2 \ln L}{\partial p^2}(x_1, \dots, x_n; p) = -\frac{1}{p^2} \sum_{i=1}^n x_i - \frac{1}{(1-p)^2} \sum_{i=1}^n (N - x_i) < 0 \implies L(x_1, \dots, x_n; \cdot)$  ia valoarea maximă pentru  $p$  găsit mai sus. Estimatorul pentru parametrul necunoscut  $p$  este  $\hat{p}(X_1, \dots, X_n) = \frac{1}{nN} \sum_{i=1}^n X_i$ .

Valoarea estimatorului, pentru ambele metode, este  $\hat{p}(x_1, \dots, x_n) = \frac{1}{nN} \sum_{i=1}^n x_i$ .

Deoarece  $E(\hat{p}(X_1, \dots, X_n)) = \frac{1}{N} E(X) = \frac{Np}{N} = p$ , estimatorul este nedeplasat. LTNM implică  $\hat{p}(X_1, \dots, X_n) \xrightarrow{a.s.} \frac{1}{N} E(X) = p$  (unde considerăm șirul de variabile de selecție  $X_1, \dots, X_n, \dots$ ) deci estimatorul este consistent.

ii) Valoarea estimatorului este  $\hat{p}(3, 4, 2, 0, 2, 1) = \frac{12}{6 \cdot 5} = 40\%$ .

2. i) O caracteristică cercetată  $X$  are funcția de densitate

$$f_X(x) = \begin{cases} \lambda^2 x e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

unde  $\lambda > 0$  este fixat. Estimați parametrul necunoscut  $\lambda$  cu metoda momentelor, respectiv metoda verosimilității maxime. Sunt estimatorii obținuți consistenți?

ii) Durata culorii roșii (în minute)  $X$  a unui anumit semafor are funcția de densitate  $f_X$  dată mai sus, cu parametrul  $\lambda > 0$  necunoscut. Un taximetrist (curios din fire) a observat următoarele durate (în minute) ale culorii roșii pentru acest semafor: 1,  $\frac{3}{2}$ , 3, 2, 3,  $\frac{5}{2}$ , 1, 2. Aplicați metoda momentelor, respectiv metoda verosimilității maxime, pentru a estima valoarea lui  $\lambda$ , folosind datele furnizate de taximetrist.

R: i) Fie  $X_1, \dots, X_n$  variabile de selecție și  $x_1, \dots, x_n$  date statistice pentru  $X$ .

Metoda momentelor:  $E(X) = \int_0^\infty \lambda^2 x^2 e^{-\lambda x} dx = \frac{2}{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i \implies \hat{\lambda}(X_1, \dots, X_n) = \frac{2n}{\sum_{i=1}^n X_i}$ .

Metoda verosimilității maxime:  $f_X(x) = \lambda^2 x e^{-\lambda x}, x > 0 \implies L(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n \lambda^2 x_i e^{-\lambda x_i} \implies \ln L(x_1, \dots, x_n; \lambda) = 2n \ln \lambda + \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n x_i$ .  $\frac{\partial \ln L}{\partial \lambda}(x_1, \dots, x_n; \lambda) = \frac{2n}{\lambda} - \sum_{i=1}^n x_i = 0 \implies \lambda = \frac{2n}{\sum_{i=1}^n x_i}$ ;  $\frac{\partial^2 \ln L}{\partial \lambda^2}(x_1, \dots, x_n; \lambda) = -\frac{2n}{\lambda^2} < 0 \implies$  estimatorul este  $\hat{\lambda}(X_1, \dots, X_n) = \frac{2n}{\sum_{i=1}^n X_i}$ .

Valoarea estimatorului, pentru ambele metode, este  $\hat{\lambda}(x_1, \dots, x_n) = \frac{2n}{\sum_{i=1}^n x_i}$ .

LTNM  $\implies \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{a.s.} E(X) = \frac{2}{\lambda}$  (unde considerăm șirul de variabile de selecție  $X_1, \dots, X_n, \dots$ )  $\implies \hat{\lambda}(X_1, \dots, X_n) = \frac{2}{\frac{1}{n} \sum_{i=1}^n X_i} \xrightarrow{a.s.} \frac{2}{\frac{2}{\lambda}} = \lambda \implies$  estimatorul este consistent.

ii) Valoarea estimatorului este  $\hat{\lambda}(1, \frac{3}{2}, 3, 2, 3, \frac{5}{2}, 1, 2) = 1$ .

**3.** Considerăm următoarele date statistice pentru masa corporală a persoanelor dintr-o anumită populație: 71 kg; 68 kg; 77 kg; 69 kg; 65 kg. Presupunem că masa corporală este o caracteristică ce urmează distribuția normală. Determinați intervale de încredere bilaterale cu nivelul de încredere 95% pentru:

- a) media masei corporale, știind că varianța masei este 125.
- b) media masei corporale, dacă abaterea standard a masei este necunoscută.
- c) varianța masei corporale.

Folosiți tabelul următor:

$norminv(0.025, 0, 1)$	$tinv(0.025, 4)$	$chi2inv(0.025, 4)$	$chi2inv(0.975, 4)$
-1.96	-2.78	0.48	11.14

R:  $n = 5$ ,  $\bar{x}_n = \frac{71+68+77+69+65}{5} = 70$ ,  $\alpha = 5\% = 0,05$ .

a)  $z_{\frac{\alpha}{2}} = norminv(0.025, 0, 1) = -1,96$ ,  $z_{1-\frac{\alpha}{2}} = -z_{\frac{\alpha}{2}}$ ,  $\sigma = \sqrt{125} = 5\sqrt{5}$ . Valoarea intervalului de încredere este:  $(\bar{x}_n + z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x}_n + z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}) = (70 - 1,96 \cdot 5, 70 + 1,96 \cdot 5) = (60,2, 79,8)$ .

b)  $t_{\frac{\alpha}{2}} = tinv(0.025, 4) = -2,78$ ,  $t_{1-\frac{\alpha}{2}} = -t_{\frac{\alpha}{2}}$ ,  $\tilde{s}_n = \sqrt{\frac{1^2+(-2)^2+7^2+(-1)^2+(-5)^2}{4}} = 2\sqrt{5}$ . Valoarea intervalului de încredere este:  $(\bar{x}_n - t_{1-\frac{\alpha}{2}} \cdot \frac{\tilde{s}_n}{\sqrt{n}}, \bar{x}_n + t_{1-\frac{\alpha}{2}} \cdot \frac{\tilde{s}_n}{\sqrt{n}}) = (70 - 2,78 \cdot 2, 70 + 2,78 \cdot 2) = (64,44, 75,56)$ .

c)  $c_{\frac{\alpha}{2}}^2 = chi2inv(0.025, 4) = 0,48$ ,  $c_{1-\frac{\alpha}{2}}^2 = chi2inv(0.975, 4) = 11,14$ . Valoarea intervalului de încredere este:  $\left(\frac{(n-1)\tilde{s}_n^2}{c_{1-\frac{\alpha}{2}}^2}, \frac{(n-1)\tilde{s}_n^2}{c_{\frac{\alpha}{2}}^2}\right) = \left(\frac{80}{11,14}, \frac{80}{0,48}\right) \approx (7,18, 166,67)$ .

**4.** Într-un sondaj de opinie, suntem interesați de proporția  $p$  a persoanelor dintr-un anumit oraș care ar vota candidatul  $A$  împotriva candidatului  $B$ .

a) Determinați un interval de încredere bilateral cu nivelul de încredere 95% pentru  $p$ , știind că 64 de persoane dintr-un eșantion de 100 de participanți la sondaj ar vota candidatul  $A$ .

b) Estimați un număr minim de participanți la sondaj pentru a obține un interval de încredere bilateral cu nivelul de încredere 95% de lungime cel mult 5%.

R: a)  $n = 100$ ,  $\bar{x}_n = 0,64$ ,  $z_{1-\frac{\alpha}{2}} = 1,96$  (a se vedea problema 4.). Valoarea intervalului de încredere este:  $(\bar{x}_n - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{x}_n(1-\bar{x}_n)}{n}}, \bar{x}_n + z_{1+\frac{\alpha}{2}} \sqrt{\frac{\bar{x}_n(1-\bar{x}_n)}{n}}) = (0,64 - 1,96 \sqrt{\frac{0,64 \cdot 0,36}{100}}, 0,64 + 1,96 \sqrt{\frac{0,64 \cdot 0,36}{100}}) = (0,64 - 1,96 \frac{0,8 \cdot 0,6}{10}, 0,64 + 1,96 \frac{0,8 \cdot 0,6}{10}) = (0,54592, 0,73408)$ .

b)  $0,95 \approx P\left(p \in (\bar{X}_n - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}}, \bar{X}_n + z_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}})\right) \leq P\left(p \in (\bar{X}_n - 1,96 \frac{1}{2\sqrt{n}}, \bar{X}_n + 1,96 \frac{1}{2\sqrt{n}})\right)$ .

Căutăm  $n$  minim astfel încât:  $\frac{0,98}{\sqrt{n}} < 2,5\% \implies \sqrt{n} > \frac{0,98}{0,025} = 39,2 \implies$  valoarea minimă estimată este 1537.

**5.** O companie dorește înlocuirea unui sistem de frânare pentru un anumit tip de mașină cu unul nou, care să reducă semnificativ distanța de frânare. Media distanței de frânare pentru vechiul sistem este mai mare sau egală decât 50 m, pentru o viteză de 80 km/h pe ploaie. Folosind tabelul de mai jos, rezolvați cerințele următoare.

i) Știind că în urma testării a 100 de mașini cu noul sistem de frânare instalat, pentru o viteză de 80 km/h pe ploaie, s-a constatat că valoarea mediei de selecție este 49 m și că valoarea abaterii standard de selecție este 1 m pentru distanța de frânare a acestui eșantion, să se construiască un interval de încredere unilateral stâng pentru media distanței de frânare a noului sistem, iar apoi să se testeze dacă noul sistem este mai performant decât cel vechi, cu un nivel de semnificație de 1%.

ii) Știind că, în condițiile precizate, abaterea standard a distanței de frânare a noului sistem de frânare este de 2 m, care este valoarea maximă a mediei distanței de frânare pentru un eșantion de 100 de mașini testate cu noul sistem de frânare pentru a concluziona, cu ajutorul unui test statistic cu un nivel de semnificație de 6%, că noul sistem este mai performant?

$x$	0.005	0.01	0.03	0.06	0.94	0.97	0.99	0.995
$norminv(x, 0, 1)$	-2.58	-2.33	-1.88	-1.55	1.55	1.88	2.33	2.58
$tinva(x, 99)$	-2.63	-2.36	-1.9	-1.57	1.57	1.9	2.36	2.63
$chi2inv(x, 99)$	66.5	69.2	74.3	78.1	121.8	127.1	134.6	139

R: i) Construim un interval de încredere unilateral stâng pentru medie, când varianța este necunoscută:  $n = 100$ ,  $\bar{x}_{100} = 49$ ,  $\tilde{s}_{100} = 1$ ,  $\alpha = 0,01$ ,  $t_\alpha = tinva(\alpha, n - 1) = tinva(0,01, 99) = -2,36$ . Valoarea intervalului de încredere este  $(-\infty, \bar{x}_{100} - \frac{\tilde{s}_{100}}{\sqrt{n}} \cdot t_\alpha) = (-\infty, 49 + \frac{1}{10} \cdot 2,36) = (-\infty, 49,236)$ .  $H_0 : m \geq 50$ ,  $H_1 : m < 50$ . Aplicăm testul pentru medie, când varianța este necunoscută:  $t = \frac{\bar{x}_{100} - 50}{\frac{\tilde{s}_{100}}{\sqrt{100}}} = \frac{49 - 50}{\frac{1}{10}} = -10$ ,  $t < t_\alpha \implies$  se respinge  $H_0$ , adică se acceptă că sistemul nou este mai performant.

ii)  $H_0 : m \geq 50$ ,  $H_1 : m < 50$ . Avem:  $\alpha = 0,06$ ,  $\sigma = 2$ ,  $z_\alpha = norminv(\alpha) = norminv(0,06) = -1,55$ ,  $z = \frac{\bar{x}_{100} - 50}{\frac{\sigma}{\sqrt{100}}} = \frac{49 - 50}{\frac{2}{10}} = -5$ . Aplicând testul pentru medie, când varianța este cunoscută, respingem ipoteza  $H_0$  în favoarea lui  $H_1$  (i.e. acceptăm că sistemul nou este mai performant) dacă și numai dacă  $z \leq z_\alpha \Leftrightarrow \frac{\bar{x}_{100} - 50}{\frac{2}{10}} \leq -1,55 \Leftrightarrow \bar{x}_{100} \leq 49,69$ . Deci valoarea maximă cerută este 49,69.

**6.** Un provider de internet își asigură clienții că viteza conexiunii la internet este în medie mai mare sau egală decât 250 Mbps între orele 20:00 și 22:00. Pe de altă parte, providerul susține că în acest interval orar conexiunea nu este stabilă, având o abatere standard de 40 Mbps. Folosind tabelul de mai jos, rezolvați cerințele următoare.

i) Știind că în urma unei selecții de 100 de clienți s-a constatat că valoarea mediei de selecție este 242 Mbps pentru viteza conexiunii între orele specificate, să se construiască un interval de încredere bilateral pentru media vitezei conexiunii, iar apoi să se testeze dacă media vitezei este cea pretinsă de provider, cu un nivel de semnificație de 5%.

ii) Care este valoarea maximă a mediei vitezei conexiunii între orele specificate pentru un eșantion de 100 de clienți, pentru a concluziona, cu ajutorul unui test statistic cu un nivel de semnificație de 4%, că media vitezei conexiunii nu este cea pretinsă de provider?

$x$	0.02	0.025	0.04	0.05	0.95	0.96	0.975	0.98
$tinva(x, 99)$	-2.08	-1.98	-1.77	-1.66	1.66	1.77	1.98	2.08
$chi2inv(x, 99)$	72.3	73.4	75.8	77	123.2	125	128.4	130
$norminv(x, 0, 1)$	-2.05	-1.96	-1.75	-1.64	1.64	1.75	1.96	2.05

R: i) Construim un interval de încredere bilateral pentru medie, când varianța este cunoscută:  $n = 100$ ,  $\bar{x}_{100} = 242$ ,  $\sigma = 40$ ,  $\alpha = 0,05$ ,  $z_{1-\frac{\alpha}{2}} = norminv(1 - \frac{\alpha}{2}) = norminv(0,975) = 1,96$ . Valoarea intervalului de încredere este  $(\bar{x}_{100} - \frac{\sigma}{\sqrt{n}} \cdot z_{1-\frac{\alpha}{2}}, \bar{x}_{100} + \frac{\sigma}{\sqrt{n}} \cdot z_{1-\frac{\alpha}{2}}) = (242 - \frac{40}{10} \cdot 1,96, 242 + \frac{40}{10} \cdot 1,96) = (234,16, 249,84)$ .

$H_0 : m \geq 250$ ,  $H_1 : m < 250$ . Aplicăm testul pentru medie, când varianța este cunoscută:  $z_\alpha = norminv(\alpha) = norminv(0,05) = -1,64$ ,  $z = \frac{\bar{x}_{100} - 250}{\frac{\sigma}{\sqrt{100}}} = \frac{242 - 250}{\frac{40}{10}} = -2$ ,  $z < z_\alpha \implies$  se respinge  $H_0$ , adică se acceptă că media vitezei conexiunii la internet nu este cea pretinsă de provider.

ii)  $H_0 : m \geq 250$ ,  $H_1 : m < 250$ . Avem:  $z_\alpha = norminv(\alpha, 0, 1) = norminv(0,04, 0, 1) = -1,75$ ,

$z = \frac{\bar{x}_{100} - 250}{\frac{40}{10}}$ . Aplicând testul pentru medie, când varianța este cunoscută, respingem ipoteza  $H_0$  în favoarea lui  $H_1$  (adică, acceptăm că media vitezei conexiunii nu este cea pretinsă de provider) dacă și numai dacă  $z \leq z_\alpha \Leftrightarrow \frac{\bar{x}_{100} - 250}{\frac{40}{10}} \leq -1,75 \Leftrightarrow \bar{x}_{100} \leq 243$ . Deci valoarea maximă cerută este 243.